

# OverHAL-Zip2HAL

## Alimenter une collection HAL à partir d'exports OpenAlex, WoS ou Pubmed

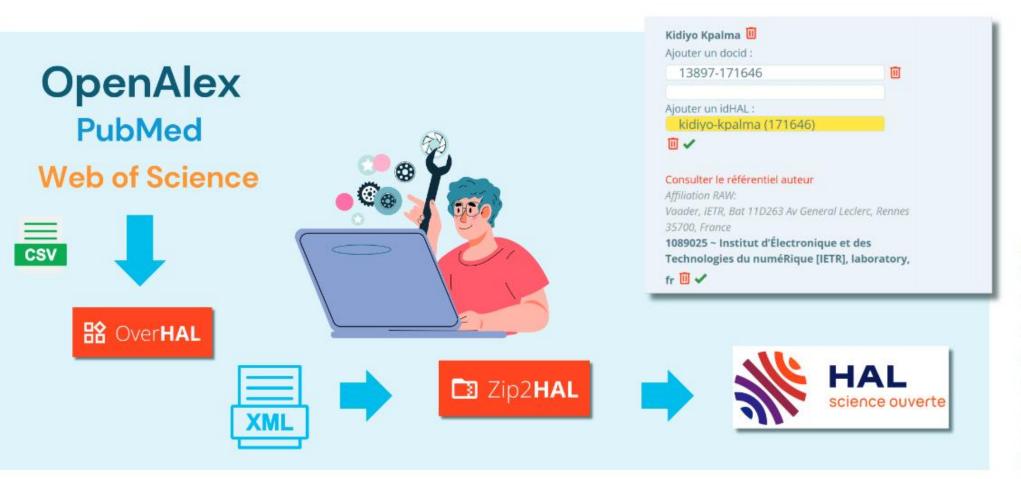
https://ccsdrennesvip.ccsd.cnrs.fr/OverHAL.php

https://ccsdrennesvip.ccsd.cnrs.fr/Zip2HAL TEI OverHAL.php



#### Vue d'ensemble : les 3 étapes du référencement

#### Les références sont créées dans HAL



OverHAL : les publications (métadonnées) sont dédoublonnées, puis converties au format XML TEI-HAL

Zip2HAL: les métadonnées sont automatiquement enrichies via les référentiels HAL (ROR, ORCID...) puis déposées dans HAL via les webservices CCSD (Sword)

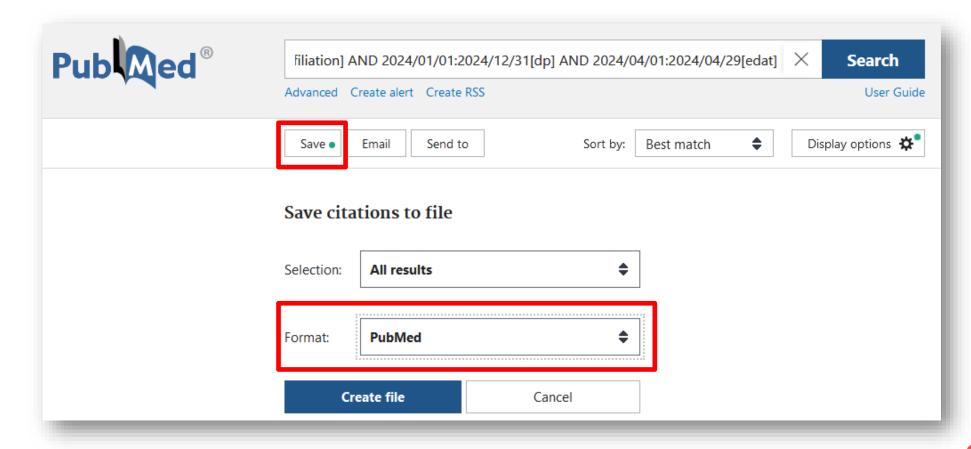
#### Etape 1:

Générer les fichiers source dans <u>OverHAL</u>

https://ccsdrennesvip.ccsd.cnrs.fr/OverHAL.php

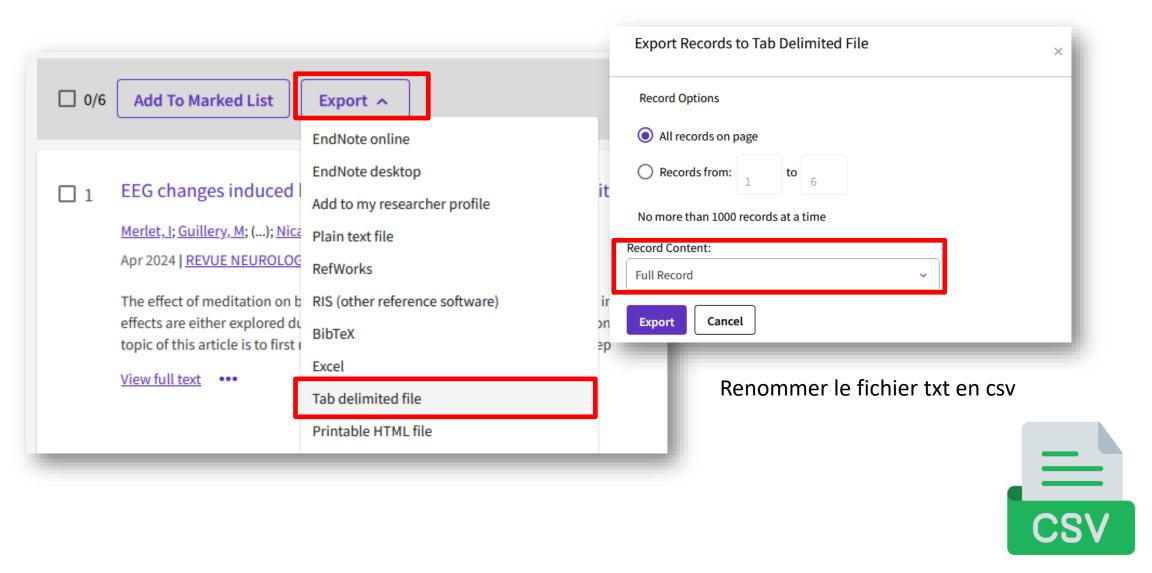


#### **OverHAL**: source Pubmed



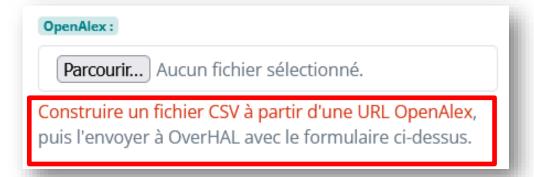


#### OverHAL: source Web of Science



#### OverHAL: source OpenAlex





Le fichier CSV est généré à partir d'une requête API (lancée via OverHAL). Il faut donc au préalable construire la requête

https://ccsdrennesvip.ccsd.cnrs.fr/OverHAL OpenAlex construct import.php



OpenAlex (URL sans critère(s) & de pagination): https://api.openalex.org/works?filter=raw\_affiliation\_strings.search:UMR6226 OR "UMR 6226" OR "ISCR (voir une URL modèle)

Envoyer



#### URL requête OpenAlex

166 notice(s)



Extraction réalisée.

Si nécessaire, vous pouvez <u>télécharger le fichier OpenAlex CSV</u> (clic droit, enregistrer sous)



#### **Focus**

Construire ses requêtes API OpenAlex (à faire une seule fois)

#### Construire ses requêtes OpenAlex



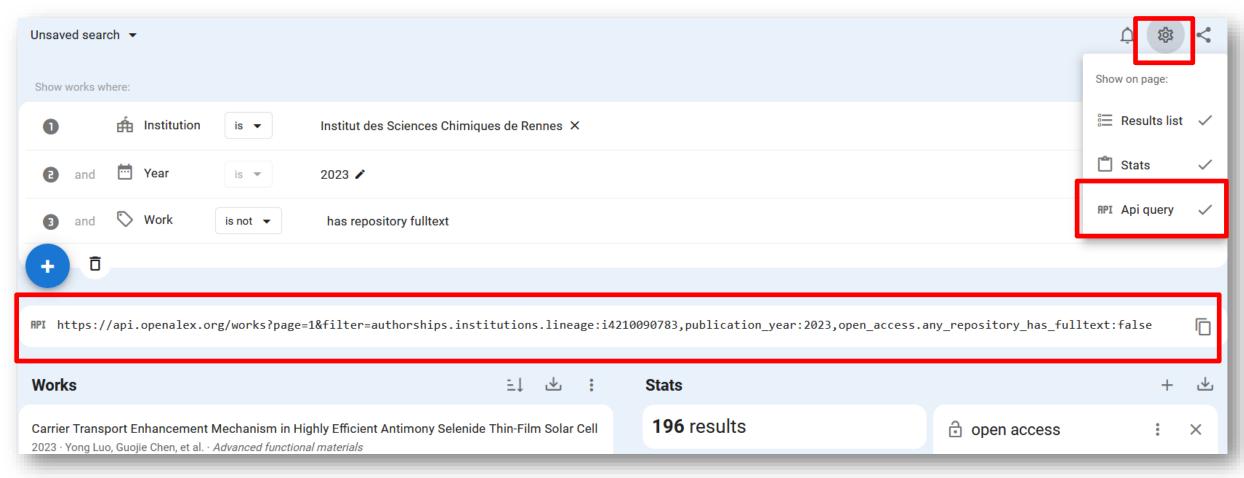
- La 1<sup>ère</sup> étape consiste à générer un fichier CSV à partir d'une requête API. Il faut donc au préalable établir la liste de vos requêtes API.
- Prendre son temps, étudier la documentation API : <a href="https://docs.openalex.org/">https://docs.openalex.org/</a>
- Partir d'exemple concrets, à partir de DOI pour repérer les différents champs (affiliations, auteurs...)
  Exemple : <a href="https://api.openalex.org/works?filter=doi:10.1111/jce.16139">https://api.openalex.org/works?filter=doi:10.1111/jce.16139</a>
- Construire sa requête en s'aidant des diapos suivantes, pas à pas, et tester l'url dans un navigateur
- Faire l'effort de déchiffrer les éléments de la requête et des champs API pour devenir autonome dans la construction de ses propres requêtes
- Possibilité d'utiliser un éditeur comme <u>Bruno</u> pour construire ses requêtes



### Construire la requête Al depuis l'interface OpenAlex



#### https://openalex.org/





**Inconvénient** : il peut y avoir des erreurs d'affiliations (calculées à partir des formes brutes)

#### Exemple d'une notice d'article OpenAlex



https://api.openalex.org/works?filter=doi:10.1016/j.cris.2024.10007

```
author_position: "first",
.'author: {
    id: https://openalex.org/A5077419455,
    display_name: "Joan van Baaren",
    orcid: https://orcid.org/0000-0002-8552-9645

author: {
    id: https://orcid.org/0000-0002-8552-9645

    id: https://openalex.org/I4210087209,
        display_name: "Ecosystèmes, Biodiversité, Evolution",
        ror: https://ror.org/005fjj927,
        country_code: "FR",
        author: "first",
        id: https://ror.org/005fjj927,
        country_code: "FR",
        author: "first",
```

L'algorithme qui calcule l'affiliation (display\_name) n'est pas toujours fiable

#### Exemple d'une notice d'article OpenAlex



https://api.openalex.org/works/doi:10.1016/j.saa.2022.121833

```
author_position: "middle",
.'author: {
   id: https://openalex.org/A5045325267,
   display_name: "Xiaoyan Yang",
   orcid: https://orcid.org/0000-0001-8508-4300
```

L'algorithme qui calcule le nom de l'auteur (display\_name) n'est pas toujours fiable

```
1
```

```
],
is_corresponding: false,
praw_author_name: "Xueying Yang",
.'raw_affiliation_strings: [

"Key Laboratory of Rare Earth Optoelectronic Materials
and Devices, China Jiliang University, Hangzhou 310018;
```



#### Construire les requêtes API OpenAlex



filter=raw\_affiliation\_strings.search: On recherche des éléments d'affiliation dans une chaîne de caractères « brute »

type: On limite notre recherche à certains types de documents (« articles » englobe les communications) https://api.openalex.org/works?group\_by=type

type\_crossref:! On exclut (!) de notre requête toutes les publications déjà référencées dans HAL (ou dans une archive ouverte primary\_location.source.type)

from\_created\_date: On filtre sur les entrées récemment créées (uniquement avec une clé API api\_key). Attention, la date de publication dans OpenAlex n'est pas toujours fiable > faire une requête élargie

On peut insérer d'autres filtres dans la requête, exemple un auteur : display\_name:Jacques Dupont

**En vert** : les éléments à mettre à jour (voir diapo suivante)

#### Requête booléenne (affiliation)



filter=raw\_affiliation\_strings.search:

(UMR6251 OR "UMR 6251" OR IPR OR "Institut de physique de Rennes" OR "Institute of Physics of Rennes" OR "Rennes Institute of Physics" OR LARMAUR OR "Mécanique et Verres") AND (France) NOT ("Institut Pierre Richet" OR "Intelligent Process Automation and Robotics" OR "Sant Joan de Déu" OR "Institut Polytechnique Rural de Formation et de Recherche Appliquée")

- Recherches booléennes : <a href="https://docs.openalex.org/how-to-use-the-api/get-lists-of-entities/search-entities#boolean-searches">https://docs.openalex.org/how-to-use-the-api/get-lists-of-entities/search-entities#boolean-searches</a>
- Ne pas mettre de virgule dans les chaînes entre guillemets : "Oncogenesis, Stress and Signaling"
- On ne peut pas faire ("Institut de Physique" AND Rennes) entre parenthèses mais ça fonctionne si on ne met pas de guillemets : (Institut de Physique AND Rennes)
- Uniquement des guillemets doubles
- Les troncatures et opérateurs de proximité ne fonctionnent pas (\* ? ~ NEAR ADJ)



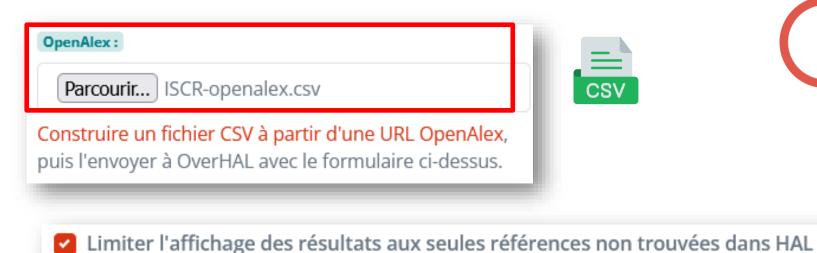
#### Etape 2:

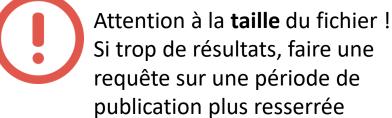
Dédoublonner + générer un fichier XML-TEI HAL

https://ccsdrennesvip.ccsd.cnrs.fr/OverHAL.php



#### OverHAL: Import du fichier CSV







**Une** seule source à la fois (OpenAlex OU Pubmed OU WoS)





**URL Joker:** 

https://hal.science/search/index?q=

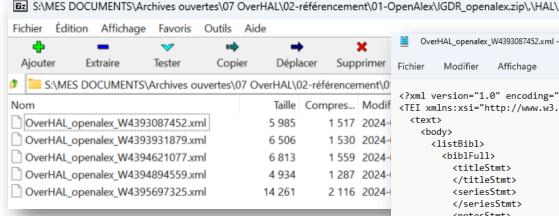
#### OverHAL: résultats + export zip

#### Références de OpenAlex non trouvées dans HAL - Retour aux résultats

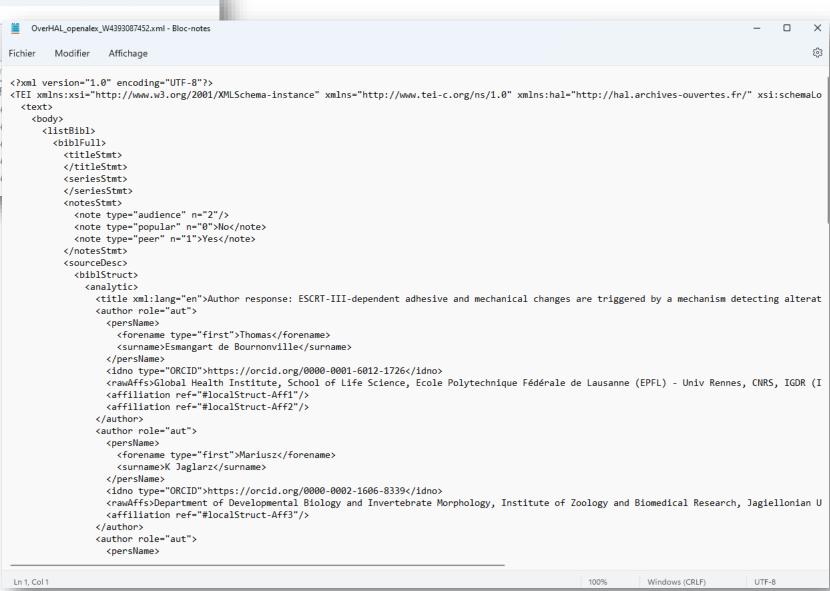
Attention, il est possible que la référence soit présente dans HAL mais qu'elle n'ait pas été trouvée en raison d'une légère différence dans le titre. Par ailleurs, les notices avec plus de 50 auteurs ne seront pas prises en compte dans l'export TEI et apparaîtront <del>barrées</del>.

	Références	DOI	Source	Joker
1	Marie Cordier, Daniel S. Müller, Marc Devillard (2024) HMPA-Free Synthesis of TMS-Substituted Alkynes - Organometallics - doi: https://doi.org/10.1021/acs.organomet.4c00091	doi	8	1
2	Gabriel Dunes, Peter M. Chapple, Samia Kahlal, Thierry Roisnel, Jean-Francois Carpentier, Jean-Yves Saillard, Yann Sarazin (2024)  Barium phosphidoboranes and related calcium complexes - Dalton transactions - doi: https://doi.org/10.1039/d4dt00487f	doi	8	
3	Mateja Seničar, Benoît Roubinet, Pierre Lafite, Laurent Legentil, Vincent Ferrières, Ludovic Landemarre, Richard Daniellou (2024) Galf-Specific Neolectins: Towards Promising Diagnostic Tools - International journal of molecular sciences - doi: https://doi.org/10.3390/ijms25094826	doi	8	
4	Hadrien Flichot, Annika Sickinger, Jules Brom, Bertrand Lefeuvre, Vincent Dorcet, Thierry Guizouarn, Olivier Cador, Boris Le Guennic, laurent.micouin@u-paris.fr laurent.micouin@u-paris.fr, Olivier Maury, erica.benedetti@u-paris.fr erica.benedetti@u-paris.fr, Fabrice Pointillart (2024) Magneto-structural correlation in lanthanide luminescent [2.2]Paracyclophane-based Single-Molecule Magnets - Dalton transactions - doi: https://doi.org/10.1039/d4dt00536h	doi	<b>3</b>	

#### Annexe: aperçu du contenu des fichiers zip



A ce stade, OverHAL a déjà calculé certaines métadonnées (affiliations) sous forme de chaîne de caractères (ex : « UMR6226 »)



Etape 3 : Déposer dans HAL

https://ccsdrennesvip.ccsd.cnrs.fr/Zip2HAL.php



#### Zip2HAL: Avertissement

- Dans Zip2HAL, l'utilisateur dépose notice par notice, l'une après l'autre. On ne traite la notice suivante qu'après avoir déposé dans HAL la précédente.
- Si la langue du document doit être modifiée, cette modification doit être réalisée en amont de toutes les autres.



- Toute modification du formulaire de saisie modifie en direct le fichier TEI.
- IMPORTANT : n'effacez jamais votre saisie avec la souris ou votre clavier. Utilisez toujours la poubelle. Sans quoi l'information risque de ne pas être effacée du TEI et bloquer votre dépôt.

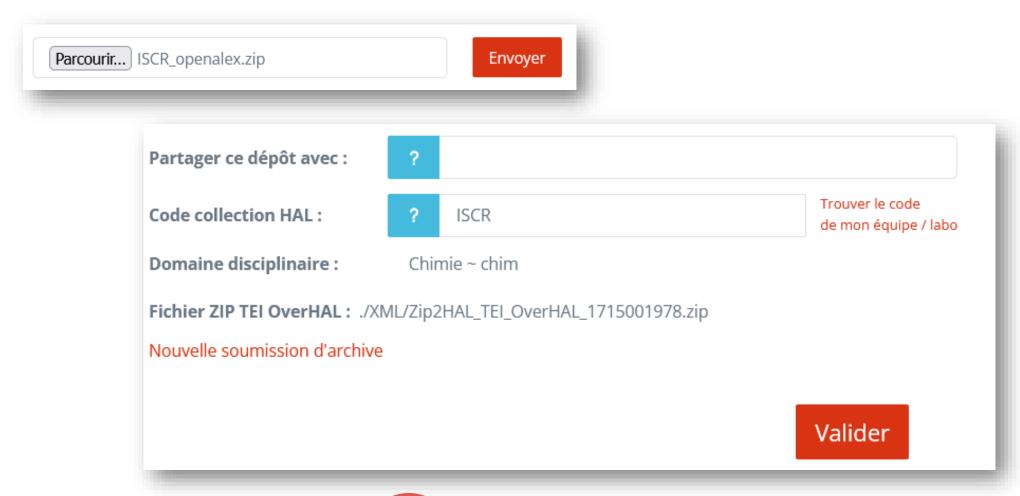


- Cliquez sur le lien DOI ou Pubmed pour comparer les données Zip2HAL et les données de l'article afin d'éviter toute erreur.
- Les données obligatoires sont indiquées par un astérisque \*





#### Zip2HAL: Chargement du fichier zip généré par OverHAL

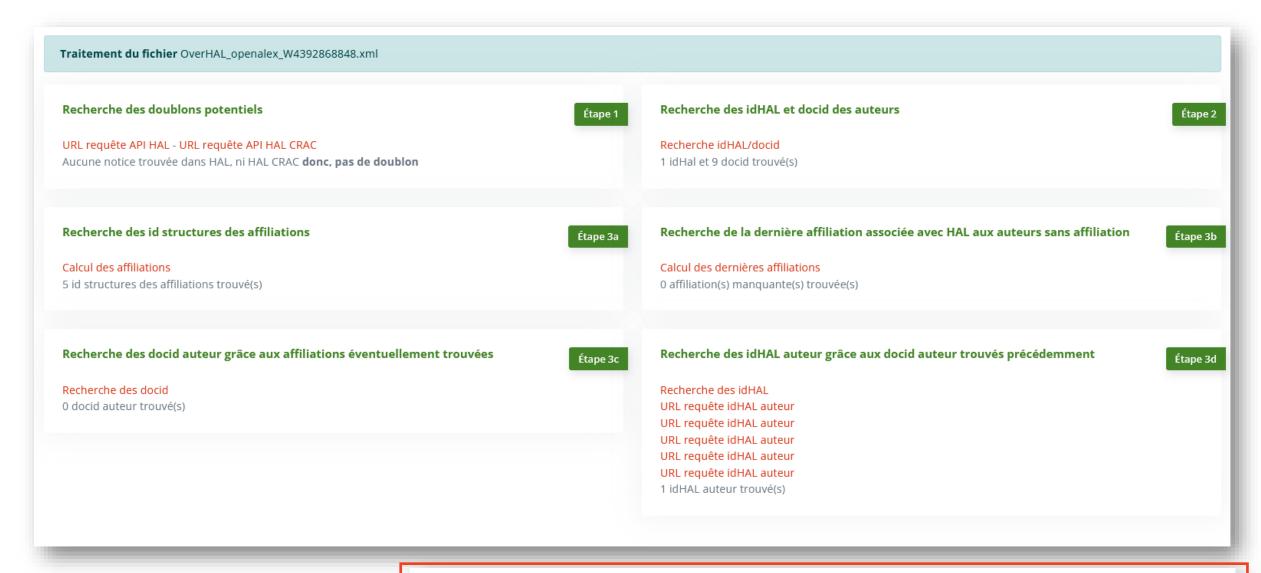




**Attendre** que le script ait terminé l'analyse du fichier avant de passer à l'étape suivante!



### Zip2HAL: étapes du traitement du fichier zip

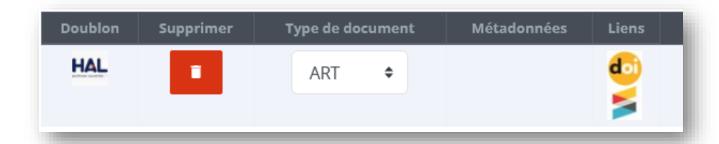




#### Zip2HAL: si la notice est déjà dans HAL (à vérifier)



Recherche des doublons sur les *n* premiers mots du titre avec troncature \* OU doi + date de publication (- / + 1 an) + à paraître >> peut manquer des doublons si légère différence dans le titre



La recherche de doublons est également faite sur les dépôts en modération (https://api.archivesouvertes.fr/crac/hal/)



#### Zip2HAL: calcul des identifiants auteurs (référentiel HAL)



```
docid: "1329555-1143868",
fullName_s: "Hanna Oher",
valid_s: "PREFERRED",

'emailDomain_s: [
        "univ-rennes1.fr"
],
idHal_i: 1143868,
idHal_s: "hanna-oher"
```

1ère méthode: recherche de l'id auteur à partir du nom complet (fullName\_t), en privilégiant l'idHAL

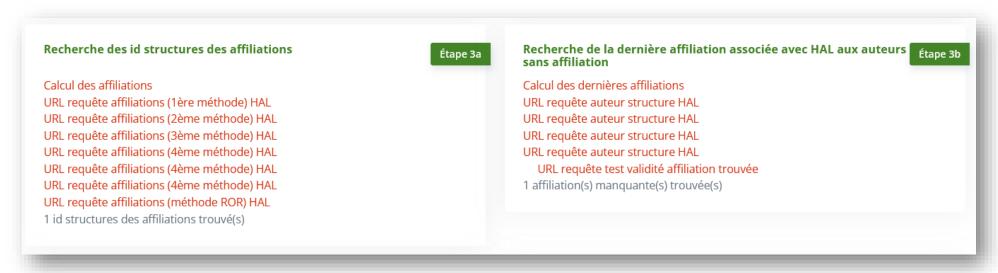
2<sup>e</sup> méthode: même chose, avec une recherche exacte (fullName\_sci)

Méthode ORCID, si la métadonnée est disponible dans le fichier OpenAlex

```
docid: "325-686",
  fullName_s: "Valérie Vallet",
  valid_s: "PREFERRED",

' orcidId_s: [
         https://orcid.org/0000-0002-2202-3858
]
```

#### Zip2HAL: calcul des affiliations



Recherche de l'affiliation par le ROR, l'acronyme, le nom ou le code UMR

```
docid: "194938",
    ror_s: [
        https://ror.org/00adwkx90
],
    name_s: "Institut des Sciences Chimiques de Rennes",
    acronym_s: "ISCR",
    country_s: "fr",
    type_s: "laboratory",
    valid_s: "VALID"
```



#### Zip2HAL: calculs supplémentaires idHAL, affiliations,



Recherche des docid auteur grâce aux affiliations éventuellement trouvées

Étape 3c

Recherche des docid

0 docid auteur trouvé(s)

Recherche des idHAL auteur grâce aux docid auteur trouvés précédemment

Étape 3d

Recherche des idHAL

URL requête idHAL auteur

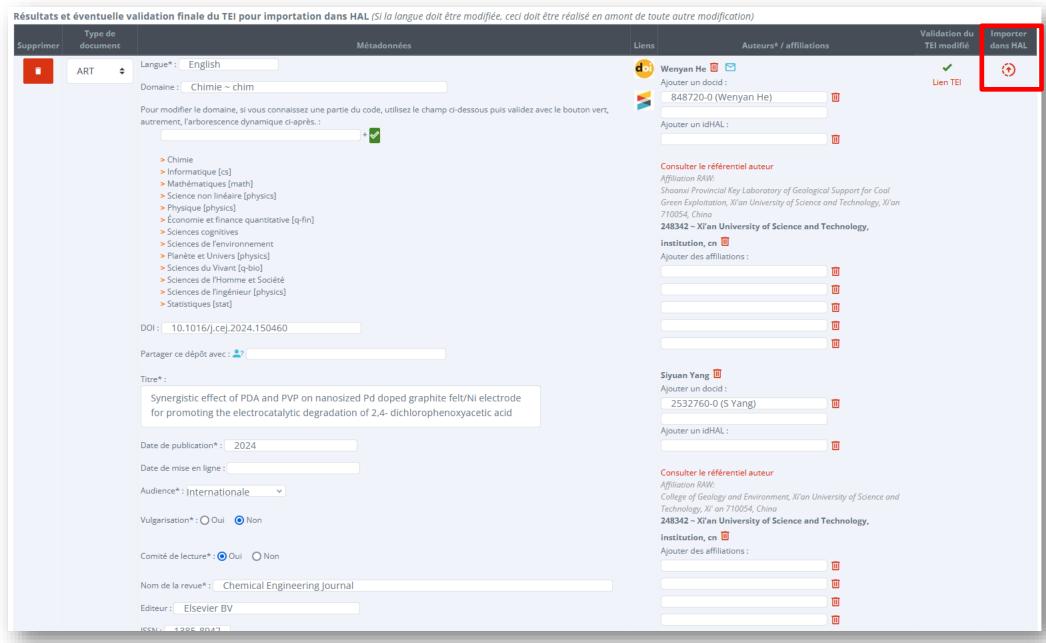
URL requête idHAL auteur

URL requête idHAL auteur

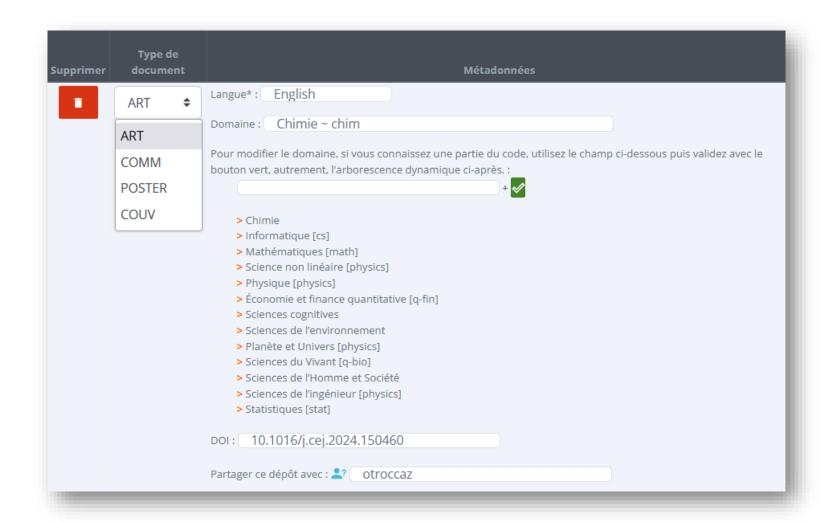
1 idHAL auteur trouvé(s)



### Zip2HAL: interface utilisateur (vue d'ensemble)



- 1. Lien DOI
- 2. Métadonnées
- 3. Auteurs et affiliations
- 4. Import dans HAL



**Type de document** : peu fiable entre ART et COMM / POSTER

**Langue** : la modification doit être faite en amont de tout autre changement (génère des champs spécifiques)

**Domaine** : sélectionner un domaine dans l'arborescence ou entrer le code et valider (ex : « sdv.ca »)

Partage du dépôt : ne fonctionne qu'avec un seul login

**Champs obligatoires** signalés par un astérisque \*



**Titre** : supprimer les éventuelles balises

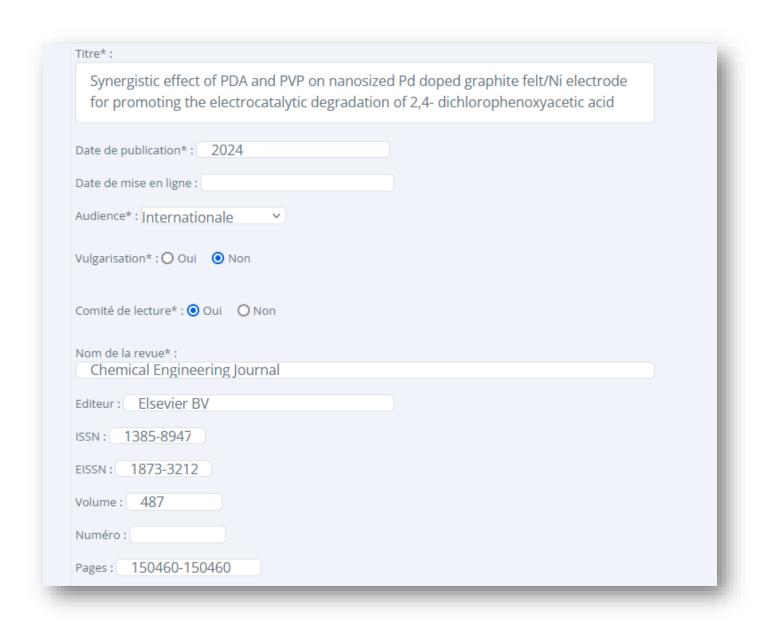
html (ex : <sub></sub>)

Audience : par défaut, « internationale »

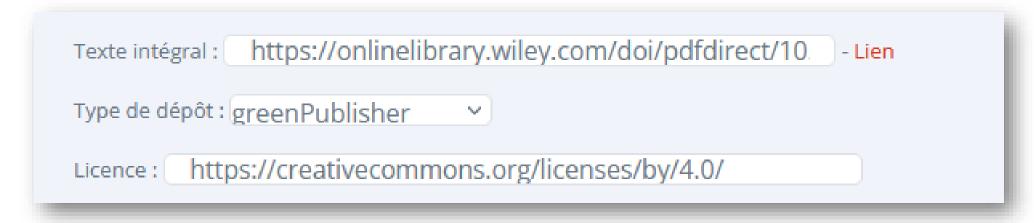
si langue = EN

ISSN/EISSN: il peut être parfois nécessaire de modifier cette donnée dans le formulaire ou dans AuréHAL (si erreur ISSN au dépôt)

**Pagination**: il s'agit parfois d'un numéro, souvent redoublé dans OpenAlex (dans cet exemple: 150460)







Le lien du fichier PDF est remonté de Unpaywall (à vérifier)

Le lien n'aboutit pas toujours à un dépôt en texte intégral dans HAL (dépend des éditeurs)

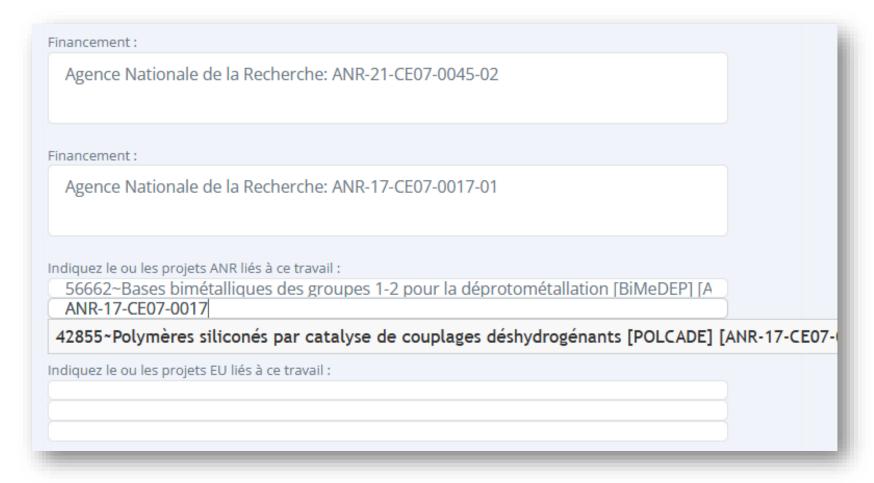
Type de dépôt = greenPublisher : correspond au champ HAL « J'ai vérifié que cet éditeur autorise le dépôt du PDF éditeur »



**Attention**: la licence CC n'est pas toujours précisée dans OpenAlex. Vérifier qu'il ne s'agit pas d'un article « free » mais sous copyright chez l'éditeur (dans ce cas, type = « No action »)



Liste des licences CC en usage pour le CCSD (format à utiliser le cas échéant)



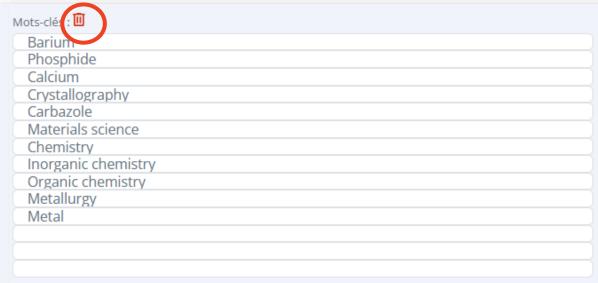
Données financement parfois absentes ou incomplètes dans openAlex (à copier-coller). « Acknowledgements » ou « Funding »

Ajouter les codes décision ANR dans les champs spécifiques (recherche dans le référentiel AuréHAL)

**Mots-clés**: ceux d'openalex ne sont pas toujours fiables et ne proviennent pas de l'éditeur. On préfère généralement les supprimer.

**Ajout de mots-clés** : données ajoutées par l'utilisateur, par copier-coller (séparateur virgule ou point-virgule)

**Résumé**: issu de CrossRef, car souvent absent ou incomplet dans OpenAlex. A remplacer le plus souvent par le résumé de l'éditeur (copiercoller)



Ajout de mots-clés dans la langue de la notice : vous pouvez renseigner ici une liste de plusieurs mots-clés séparés par des virgules ou points-virgules.

2,4-dichlorophenoxyacetic acid;

Polydopamine;

Polyvinyl pyrrolidone;

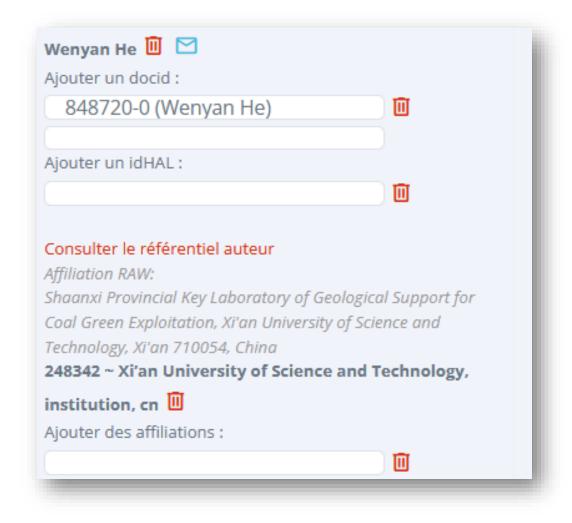
Pd catalyst;

Electrocatalytic degradation

#### Résumé:

Although a stable {N^N^N}BaPH2 phosphide supported by a bis(imino)carbazole is elusive, barium and calcium phosphidoborane complexes incorporating BH3 or B(C6F5)3 moities have been obtained. NMR, crystallographic and computational data are provided.



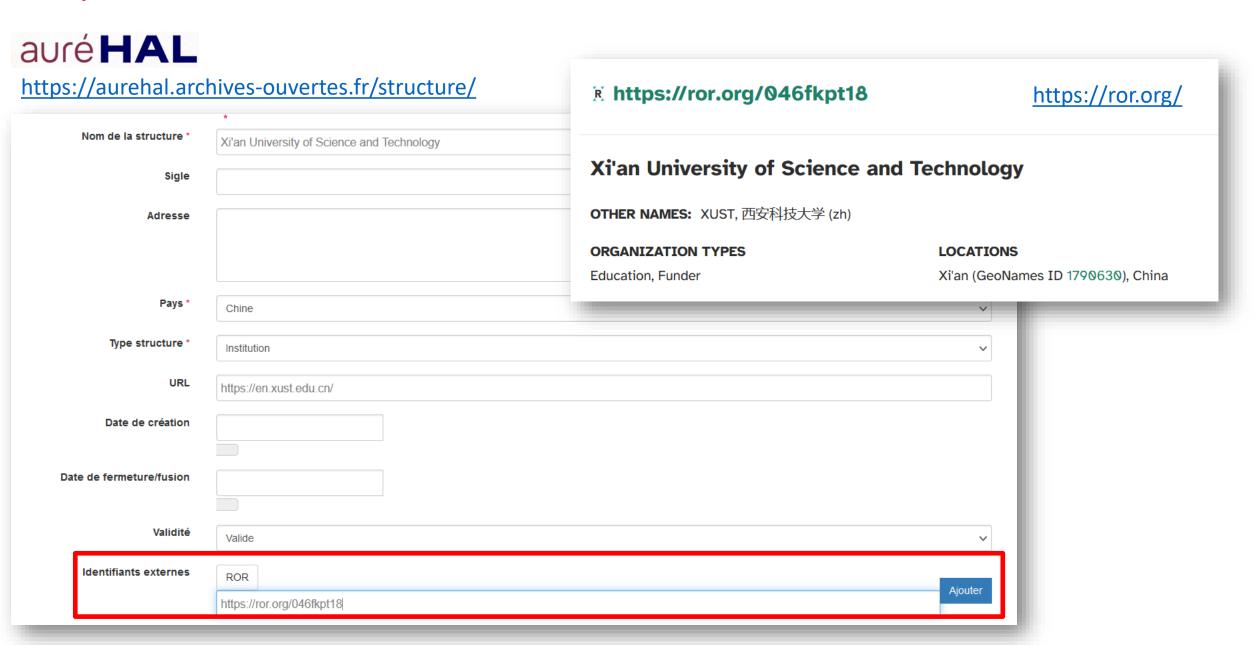


**Auteur**: le script a trouvé dans AuréHAL une forme auteur sans identifiant associé (email, ORCID, etc): 84720 (ID Forme) et 0 (ID Auteur) – **attention**: toujours bien vérifier que le nom ajouté dans le champ correspond bien au nom affiché en gras, il peut y avoir de fausses correspondances (l'algorithme n'est pas infaillible)

L'icône enveloppe signale un auteur correspondant

**Affiliation**: comparer la source (en gris) issue d'OpenAlex et la forme calculée (en gras) pour **vérifier que l'affiliation retournée est correcte**. Il manque l'encoche verte pour signaler que le calcul a été fait sur le ROR > le ROR est probablement manquant dans AuréHAL > l'ajouter : à la prochaine itération, le script retrouvera le ROR





#### Zip2HAL: auteurs et affiliations

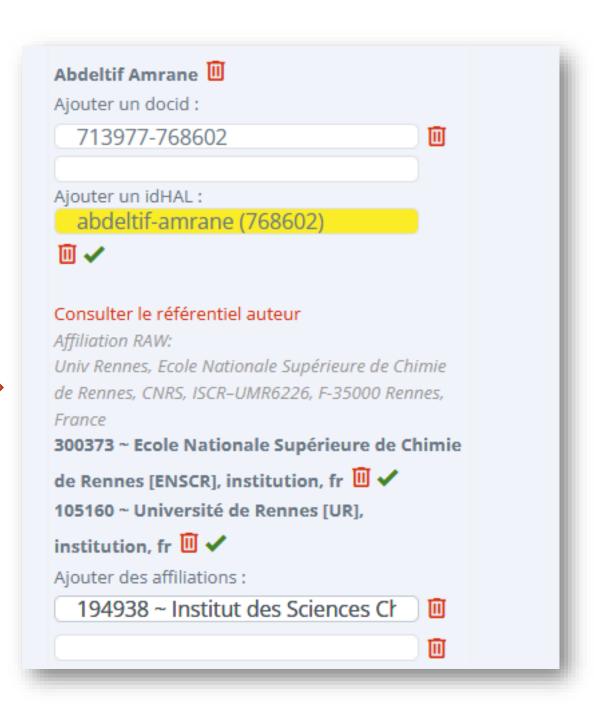
L'idHAL a été remonté grâce à l'ORCID (encoche verte)

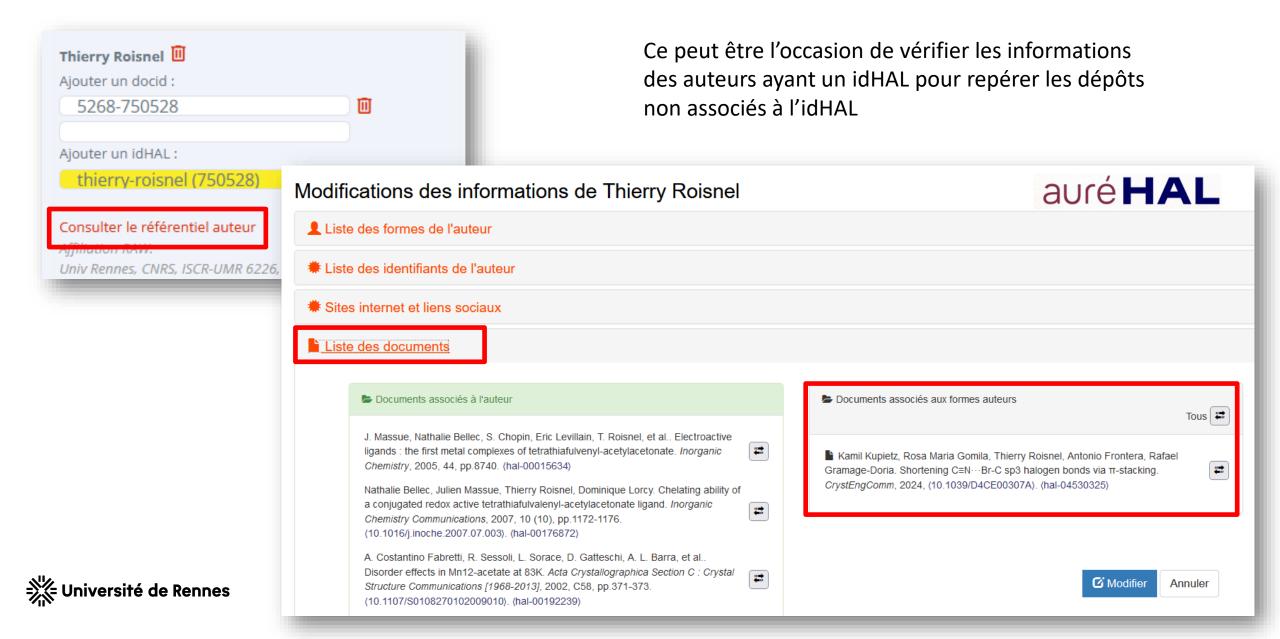
Les ROR des affiliations ont été trouvés dans AuréHAL (encoche verte)

Une affiliation manquante (UMR6226), pour laquelle le ROR existe, mais que l'algorithme d'OpenAlex n'a pas su calculer

Importance de la charte de signature dans les articles : le nom de l'unité n'est pas renseigné, l'acronyme et le code UMR sont difficilement identifiables pour l'algorithme (une seule chaîne « ISCR-UMR6226 »). Comparer :

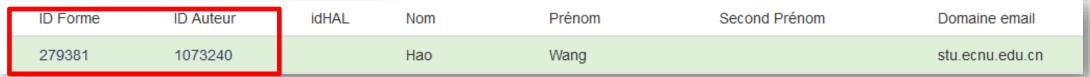






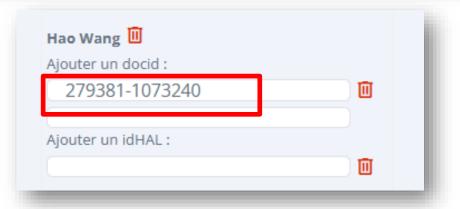


Le docid auteur retourné est faux : il faut le supprimer (icône poubelle) et rechercher le bon docid dans AuréHAL – s'il existe



Il suffit ensuite de copier-coller le docid AuréHAL



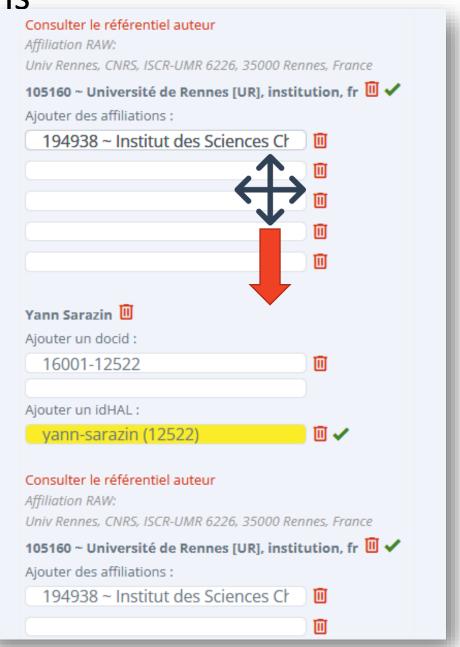




Ne pas lâcher la souris lorsqu'on ajoute une affiliation supplémentaire dans le formulaire (saisie texte) – risque d'inscrire une donnée erronée dans le XML

Toujours utiliser le bouton « poubelle » pour supprimer une donnée

Glisser-déposer avec la souris pour ajouter la même affiliation à plusieurs auteurs





#### Zip2HAL: Absence de DOI

Faire une recherche dans l'extension Google Scholar pour retrouver un éventuel DOI et s'assurer qu'on ne crée pas un doublon





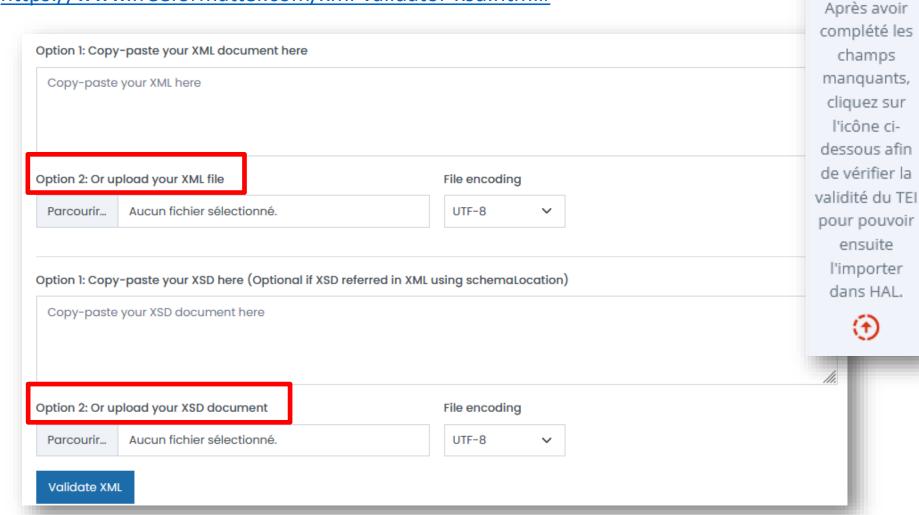


### Zip2HAL: validation du TEI modifié



FreeFormatter permet de repérer les erreurs qui empêchent la validation du TEI

#### https://www.freeformatter.com/xml-validator-xsd.html#



Validation du TEI modifié



Document XSD: <a href="https://hal.science/documents/aofr.xsd">https://hal.science/documents/aofr.xsd</a>

### Zip2HAL: Lien TEI et dépôt



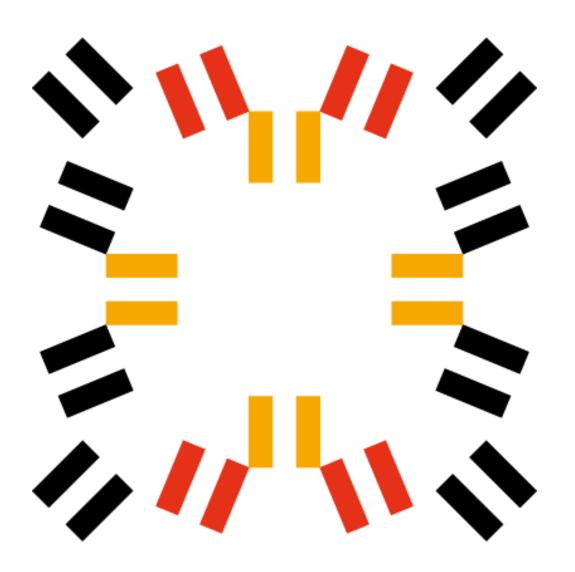
Pas d'import par lot, on importe la notice une fois les métadonnées vérifiées

```
-<TEI xsi:schemaLocation="http://www.tei-c.org/ns/1.0 http://api.archives-ouvertes.fr/documents/aofr-sword.xsd">
  -<text>
    -<body>
      -tBibl>
         -<bih>til>
            <titleStmt> </titleStmt>
           -<editionStmt>
             -<edition>
                <ref type="file" subtype="greenPublisher" n="1" target="https://pubs.rsc.org/en/content/articlepdf/2024/su/d3su00470h"/>
              </edition>
            </editionStmt>
           -<publicationStmt>
             -<availability>
                licence target="https://creativecommons.org/licenses/by/4.0/"/>
              </availability>
            </publicationStmt>
           -<seriesStmt>
              <idno type="stamp" n="UNIV-RENNES1"/>
            </seriesStmt>
```

### Zip2HAL: erreurs Sword les plus courantes

Erreurs Sword	Solutions
Code retour http: 0 ERREUR: <b>Problème avec l'API sword</b> , contactez le support technique (erreur http=0)	Vérifier dans Mes dépôts : le dépôt est effectif malgré le message d'erreur
Code retour http: 400 ERREUR: Pb sword: Internal server error: <b>Firstname</b> (Pierre-olivier) <b>is invalid</b>	Supprimer l'auteur dont l'affiliation ou la forme empêche le dépôt et l'ajouter ensuite dans la notice HAL créée
Code retour http: 400 ERREUR: Pb sword: {"duplicate-entry": {"hal- 04575964": {"doi": "1.0", "pubmed": "1.0"}}}	Notice doublon non détectée par le script (titre différent, absence de DOI, preprint avec le même DOI)
Code retour http: 400 ERREUR: Pb sword: {"mainmeta":{"mainDomain":{"isEmpty":"Cette valeur est obligatoire et ne peut \u00eatre vide"}}}	Le domaine disciplinaire n'a pas été renseigné
Code retour http: 400 ERREUR: Pb sword: Could not open the XML description: source XML incorrecte: DOMDocument::loadXML(): Start tag expected, '<' not found in Entity, line: 2	Bug sur le fichier XML (non résolu à ce jour)





Laurent.jonchere[at]univ-rennes.fr

https://scienceouverte.univ-rennes.fr/

